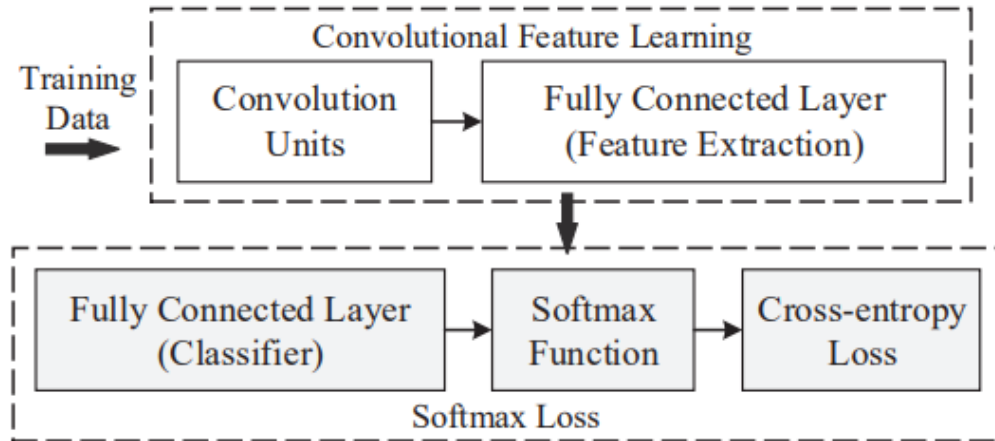


*Softmax Loss

Softmax Loss



$$SL = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} * \log\left(\frac{e^{z_{i,k}}}{\sum_{j=1}^K e^{z_{i,j}}}\right)$$
$$= -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} * \log\left(\frac{e^{\|W_{y_k}\| \|x_i\| \cos(\theta_{y_{i,k}})}}{\sum_{j=1}^K e^{\|W_{y_{i,j}}\| \|x_i\| \cos(\theta_{y_{i,j}})}}\right)$$

- $y_{i,k}$ 表示第i个样本属于第k个类别的真是标签,当样本i属于类别k时, $y_{i,k} = 1$,否则 $y_{i,k} = 0$
- $z_{i,k}$ 是样本i关于类别k的logits,全连接的输出结果就叫做logits
- N表示样本数
- K表示类别数
- 全连接层可以认为是基于距离函数为余弦相似度的线性分类器

L-Softmax

$$LSL = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} * \log\left(\frac{e^{\|W_{y_{i,k}}\| \|x_i\| \psi(\theta_{y_{i,k}})}}{\sum_{j \neq y_{i,j}} e^{\|W_{y_{i,j}}\| \|x_i\| \cos(\theta_{y_{i,j}})} + e^{\|W_{y_{i,k}}\| \|x_i\| \psi(\theta_{y_{i,k}})}}\right)$$
$$\psi(\theta) = \begin{cases} \cos(m\theta) & 0 \leq \theta \leq \frac{\pi}{m} \\ D(\theta) & \frac{\pi}{m} < \theta \leq \pi \end{cases}$$

论文中设计如下

$$\psi\theta = (-1)^k \cos(m\theta) - 2k$$
$$\theta \in \left[\frac{k\pi}{m}, \frac{(k+1)\pi}{m}\right]$$
$$k \in [0, m-1]$$

其中 m 为正整数,m越大,分类边距越大

A-Softmax

不同于L-Softmax,将分类器权重W归一化为1

$$ASL = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{i,k} * \log\left(\frac{e^{\|x_i\| \psi(\theta_{y_{i,k}})}}{\sum_{j \neq y_{i,j}} e^{\|x_i\| \cos(\theta_{y_{i,j}})} + e^{\|x_i\| \psi(\theta_{y_{i,k}})}}\right)$$
$$\psi\theta = (-1)^k \cos(m\theta) - 2k$$
$$\theta \in \left[\frac{k\pi}{m}, \frac{(k+1)\pi}{m}\right]$$
$$k \in [0, m-1]$$

AM-Softmax

Additive Angular Margin Loss

更改为了新的 $\psi(\theta) = 30 * (\cos(\theta) - m)$

可以看作是对角度距离的优化,相比于余弦距离来说,当角度接近0和 π 时,余弦值会更密集.因此推测优化角度距离比优化余弦距离更有效果.

参考

[一文看懂softmax loss](#)

[理解L-Softmax、A-Softmax 和 AM-Softmax](#)

[AM-Softmax](#)

[happyneer技术专栏](#)

[Softmax理解之margin](#)

[从最优化的角度看待Softmax损失函数](#)

[Additive Margin Softmax for Face Verification](#)